

Trabajo Práctico N°1

Análisis y Visualización de Datos – Black Friday

Input

1. Dataset Black Friday (**Kaggle** / **Analytics Vidhya**).

Entregables

1. Se puede ir desarrollando cada punto en la misma notebook donde se escriba el código.
 2. Se debe subir el entregable a un repositorio GitHub o enviar el link a un Google Colab.
 3. Tener en cuenta que si bien pueden realizar diversos análisis y visualizaciones, se debe dejar en el entregable sólo aquello que sea relevante.
 4. Luego de cada análisis es importante poder obtener una conclusión de lo observado.
-

1. Familiarización con el dataset

- a. Importar y analizar el dataset para ver con qué datos contamos, en cantidad y calidad: 1. Indagar el tipo de cada dato: 1. Categóricos 1. Numéricos 1. Analizar la naturaleza de las variables: 1. Demográficas (edad, género, estado civil) 1. Geográficas (tipo de ciudad, residencia) 1. Producto (categorías) 1. Comportamiento de compra
 - b. ¿Tenemos forma de identificar de manera única a cada cliente? ¿Cuántos clientes únicos (**User_ID**) tenemos en el dataset?
 - c. ¿Tenemos información temporal en el dataset? En caso de no contar con fechas: 1. ¿Qué implicancias tiene para el análisis? 1. ¿Qué limitaciones introduce?
 - d. ¿Tenemos datos nulos? ¿En qué variables aparecen? ¿Qué interpretación de negocio podrían tener? (por ejemplo: productos sin categoría secundaria o terciaria). Pensando en el dataset: ¿tenemos datos "suficientes" para pensar en realizar un modelo predictivo?
 - e. ¿Tenemos la columna target (necesaria en problemas de aprendizaje supervisado)? 1. Identificar la variable objetivo: **Purchase** 1. Tipo de problema: Regresión 1. ¿Qué representa esta variable desde el punto de vista de negocio?
-

2. Análisis y Visualización de los datos

a. Para los datos numéricos, realizar una breve descripción de resumen estadísticos (mínimo, máximo, media, mediana, cuantiles). Aplicar principalmente sobre la variable **Purchase**.

b. Visualizar la distribución de los features empleando gráficos como **Histogramas** y **Boxplots**. Identificar: 1. Valores atípicos (**outliers**) 1. Asimetrías 1. Posibles datos faltantes

[!NOTE] Cuando los subconjuntos tienen números desiguales de observaciones, comparar sus distribuciones en términos de recuentos puede no ser ideal. Una solución es normalizar los recuentos.

c. Analizar la distribución de la variable target (**Purchase**): ¿Está sesgada? ¿Existen valores extremos? ¿Cómo es el comportamiento general del gasto?

d. Comparar el comportamiento de los clientes en términos de su gasto (**Purchase**) según:

1. **i.** Género (**Gender**)
1. **ii.** Edad (**Age**)
1. **iii.** Estado civil (**Marital_Status**)
1. **iv.** Ocupación (**Occupation**)
1. **v.** Tipo de ciudad (**City_Category**)
1. **vi.** Años en la residencia actual (**Stay_In_Current_City_Years**)
1. **vii.** Categorías de producto (**Product_Category_1**, **Product_Category_2**, **Product_Category_3**)
1. **viii.** ¿Cuál es la distribución de los clientes por género?
1. **ix.** ¿Qué grupos etarios presentan mayor gasto?
1. **x.** ¿Dónde se encuentra el mayor número de clientes?
1. **xi.** ¿Cuántos productos únicos (**Product_ID**) tiene el dataset?
1. **xii.** ¿Cuáles son las categorías de productos más frecuentes?
1. **xiii.** ¿Qué combinaciones de categorías están asociadas a mayor gasto?
1. **xiv.** ¿Cuáles son los productos con mayor monto de compra?
1. **xv.** Analizar el comportamiento de clientes con valores faltantes en **Product_Category_2** y **Product_Category_3**.
1. **xvi.** ¿Cómo se comporta el gasto (**Purchase**) en presencia de datos faltantes?

e. En base a los puntos anteriores, analizar la relación entre las variables y la variable target (**Purchase**).

f. Segmentar el target en grupos (por ejemplo: bajo, medio, alto gasto): 1. Analizar diferencias entre segmentos. 1. Caracterizar cada grupo.

g. ¿Cuáles columnas resultan “interesantes” para ser incluidas en un futuro modelo predictivo? Debieran ser aquellas que presentan diferencias significativas en el comportamiento del gasto.