

Trabajo Práctico N°2

Análisis Exploratorio y Curación de Datos – Black Friday

Input

- Dataset Black Friday (**Kaggle / Analytics Vidhya**) o el archivo input editado del TP N°1, si hubiesen realizado alguna modificación.

Entregables

- Se puede ir desarrollando cada punto en la misma notebook donde se escriba el código.
 - Se debe subir el entregable a un repositorio GitHub o enviar el link a un Google Colab.
 - Tener en cuenta que si bien pueden realizar diversos análisis y visualizaciones, se debe dejar en el entregable sólo aquello que sea relevante.
 - Luego de cada análisis es importante poder obtener una conclusión de lo observado.
-

1. Valores nulos, **outliers** o erróneos

a. Analizar los valores nulos existentes y su impacto en el análisis del problema: * **i.** ¿Qué porcentaje representan los registros nulos de cada variable con respecto al total? Especial foco en **Product_Category_2** y **Product_Category_3**. * **ii.** En base a esas cantidades, decidir si es posible: * Eliminar registros * Imputarlos * Mantenerlos (si tienen significado de negocio) * **iii.** Verificar si existen registros duplicados que pudieran representar un problema al modelo de regresión. ¿Qué acción tomaría sobre ellos?

b. Analizar si existen valores **outliers** en las variables numéricas, principalmente en **Purchase**: * Indagar: * ¿Son valores atípicos o clientes de alto valor? * ¿Qué porcentaje representan? * Decidir: * Eliminarlos * Capearlos (**winsorization**) * Mantenerlos

c. ¿Existen valores erróneos? Ejemplos a analizar: * Valores inconsistentes en edad * Categorías inválidas * Valores fuera de rango * Definir cómo tratarlos: eliminar, imputar, mantener (si tienen lógica de negocio)

d. Concluir luego de la “limpieza”: * ¿Cuántos registros se mantuvieron? * ¿Cuántos se eliminaron? * Evaluar el impacto en la cantidad de datos disponible para modelar.

e. Analizar cómo quedó la distribución de la variable target (**Purchase**) luego de la limpieza: * ¿Se modificó la distribución? * ¿Se redujeron los **outliers**?

2. Transformación de datos existentes

- a. Pensar en nuevas columnas (**Feature Engineering**) que puedan ser útiles. Algunas ideas: * Número de categorías asociadas a un producto. * Indicador de si el producto tiene múltiples categorías. * Segmentos de edad (ej: joven, adulto, senior). * Segmentación de clientes según gasto (bajo, medio, alto). * Interacciones: * **Edad** × **Categoría de producto** * **Ciudad** × **Gasto promedio** * Sean creativos generando nuevas variables.
- b. Pasar las variables categóricas (strings) a numéricas. Analizar cuál método es más adecuado según el caso: * **One Hot Encoding** * **Label Encoding**
- c. Transformar los features numéricos: * **Escalado** * **Normalización** * **Estandarización** * Especial foco en: la variable **Purchase** (si se desea modelar con transformaciones como log).

3. Correlaciones

- a. Verificar mediante una matriz de correlación: * La correlación entre variables numéricas. * La correlación entre features y la variable target **Purchase**.
- b. Eliminar features altamente correlacionadas. Justificación: * Evitar redundancia * Mejorar la estabilidad del modelo

4. Generar dataset “limpio”

Guardar en un nuevo archivo **.csv** el dataset resultante:

- Sin valores erróneos.
 - Con imputaciones realizadas.
 - Con nuevas features generadas.
 - Con variables categóricas y numéricas adecuadamente transformadas.
- *Este dataset será utilizado en los siguientes TPs para el modelado predictivo.*