

Trabajo Práctico N°3

Modelos Supervisados y No Supervisados – Black Friday

Input

- Dataset Black Friday "limpio" (generado en el último paso del TP N°2).

Entregable

- Se puede ir desarrollando cada punto en la misma notebook donde se escriba el código.
 - Se debe subir el entregable a un repositorio GitHub o enviar el link a un Google Colab.
 - Tener en cuenta que si bien pueden realizar diversos análisis y pruebas, se debe dejar en el entregable sólo aquello que sea relevante.
 - Luego de cada modelo o análisis, es importante poder obtener una conclusión de los resultados obtenidos.
-

1. Preparación de los datos para el modelado

a. Separar el conjunto de datos: - Definir la variable objetivo / target (**Purchase**). - Definir las variables predictoras / features (el resto de las columnas útiles).

b. División en Entrenamiento y Prueba (**Train / Test Split**): - Separar los datos utilizando una proporción adecuada (por ejemplo, 80% train / 20% test). - ¿Por qué es importante realizar esta división antes de entrenar los modelos?

2. Modelos Supervisados (Regresión)

a. Definición de un **Baseline** (Modelo Base): - Plantear un modelo base simple. Por ejemplo, predecir el monto de compra utilizando siempre la media o mediana del target en el conjunto de entrenamiento. - Analizar y justificar claramente cuál es la métrica más adecuada a optimizar para este problema. - Calcular la métrica elegida para el **baseline**. Esto servirá para comparar los modelos más complejos.

b. Entrenamiento de modelos de regresión: - Entrenar al menos dos modelos diferentes. Ejemplos sugeridos: - Regresión Lineal (**Linear Regression / Ridge / Lasso**) - Árboles de Decisión (**Decision Tree Regressor**) - **Random Forest Regressor** - Modelos de Boosting (**LightGBM** o **XGBoost**)

c. Evaluación y comparación de modelos: - Predecir sobre el conjunto de test. - Evaluar los modelos entrenados utilizando la métrica seleccionada y justificada previamente. Adicionalmente, reportar otras métricas de regresión relevantes. - Comparar los resultados frente al modelo **Baseline**. ¿Qué modelo tuvo el mejor desempeño?

d. Optimización de Hiperparámetros: - Tomar el mejor modelo obtenido en el punto anterior. - Utilizar técnicas como **Grid Search CV** o **Random Search CV** para encontrar los mejores hiperparámetros. - ¿Mejoró significativamente el resultado luego de la optimización?

e. Interpretación de Resultados (**Feature Importance**): - Para el mejor modelo entrenado, graficar la importancia de las variables (**Feature Importance**). - ¿Cuáles son las variables que más influyen en el monto de compra (**Purchase**)? ¿Tienen sentido desde el punto de vista del negocio?

3. Modelos No Supervisados (Clustering)

a. Selección y preparación de variables: - Seleccionar un subconjunto de variables relevantes para agrupar clientes (por ejemplo, características demográficas o de comportamiento de compra). - Asegurarse de escalar/normalizar los datos, ya que los algoritmos de clustering son sensibles a la escala.

b. Aplicación de un algoritmo de Clustering: - Utilizar **K-Means** u otro algoritmo pertinente. - Utilizar el Método del Codo (**Elbow Method**) o el Coeficiente de **Silhouette** para determinar el número óptimo de clusters (**k**).

c. Análisis de los clusters (Segmentación de clientes): - Asignar a cada cliente (o registro) su cluster correspondiente. - Analizar las características medias de cada grupo. - ¿Se pueden identificar perfiles claros de clientes? (Ej: "Clientes jóvenes de alto gasto", "Familias de bajo ticket", etc.)

4. Conclusiones Finales

a. Impacto en el negocio: - ¿Cómo podría la empresa **ABC Private Limited** utilizar el modelo de regresión para aumentar sus ventas? - ¿Qué acciones de marketing diferenciadas se podrían tomar en base a los clusters descubiertos? - Reflexión final sobre el desempeño del modelo: ¿Es lo suficientemente bueno para ser llevado a producción?